Video Language Model

이미지 VLM

- **정지 이미지** 이해 (캡셔닝, OCR, 문서/차트 분석, Multimodal RAG)
- 이미지는 "한 장의 정보" — 모델이 한 번에 전체를 보고 답하면 됨

영상은 다르다

- 영상 = **시간 축(Temporal)** 이 추가된 이미지의 연속
- "무엇이 보이는가"뿐 아니라 "무엇이 어떻게 변하는가/일어났는가"까지 이해해야 함
- 초당 24~30장의 프레임 × 수 분 = 수만 장의 이미지 → **그대로 다 넣을 수 없음**

> 핵심 질문: **영상을 어떻게 잘라서, 얼마나, 어떤 순서로 VLM에 넣고, 결과를 어떻게 검색·설명할 것인가**

1. 영상과 VLM

- 이미지 VLM vs Video VLM
- 영상 이해의 난제
- Video VLM 아키텍처 3가지 패턴

이미지 VLM vs Video VLM

구분	이미지 VLM	Video VLM
입력	정지 이미지 1장(또는 여러 장)	시간 순서가 있는 프레임 시퀀스
이해 대상	공간적 관계(무엇이 어디에 있는가)	공간 + 시간적 관계(무엇이 어떻게 변하는가)
토큰 비용	이미지 1장 = 고정 토큰	프레임 수에 비례 → 쉽게 폭발
대표 태스크	캡셔닝, OCR, VQA	요약, 이벤트 탐지, 행동 인식

영상 이해의 난제

- **프레임 수 vs 컨텍스트 길이**: 1분 영상(30fps) = 1,800프레임 → 전부 넣으면 토큰 한도 초과
- **정보 손실**: 프레임을 듬성듬성 뽑으면(sampling) 짧은 이벤트를 놓칠 수 있음
- **로컬 모델의 한계**: Qwen3-VL(Ollama)은 영상 파일을 직접 받지 않음 → **프레임 이미지로 변환해서 전달**해야 함

> "토큰" 개념이 영상에서는 훨씬 더 중요해짐 — 프레임 수 = 토큰 비용

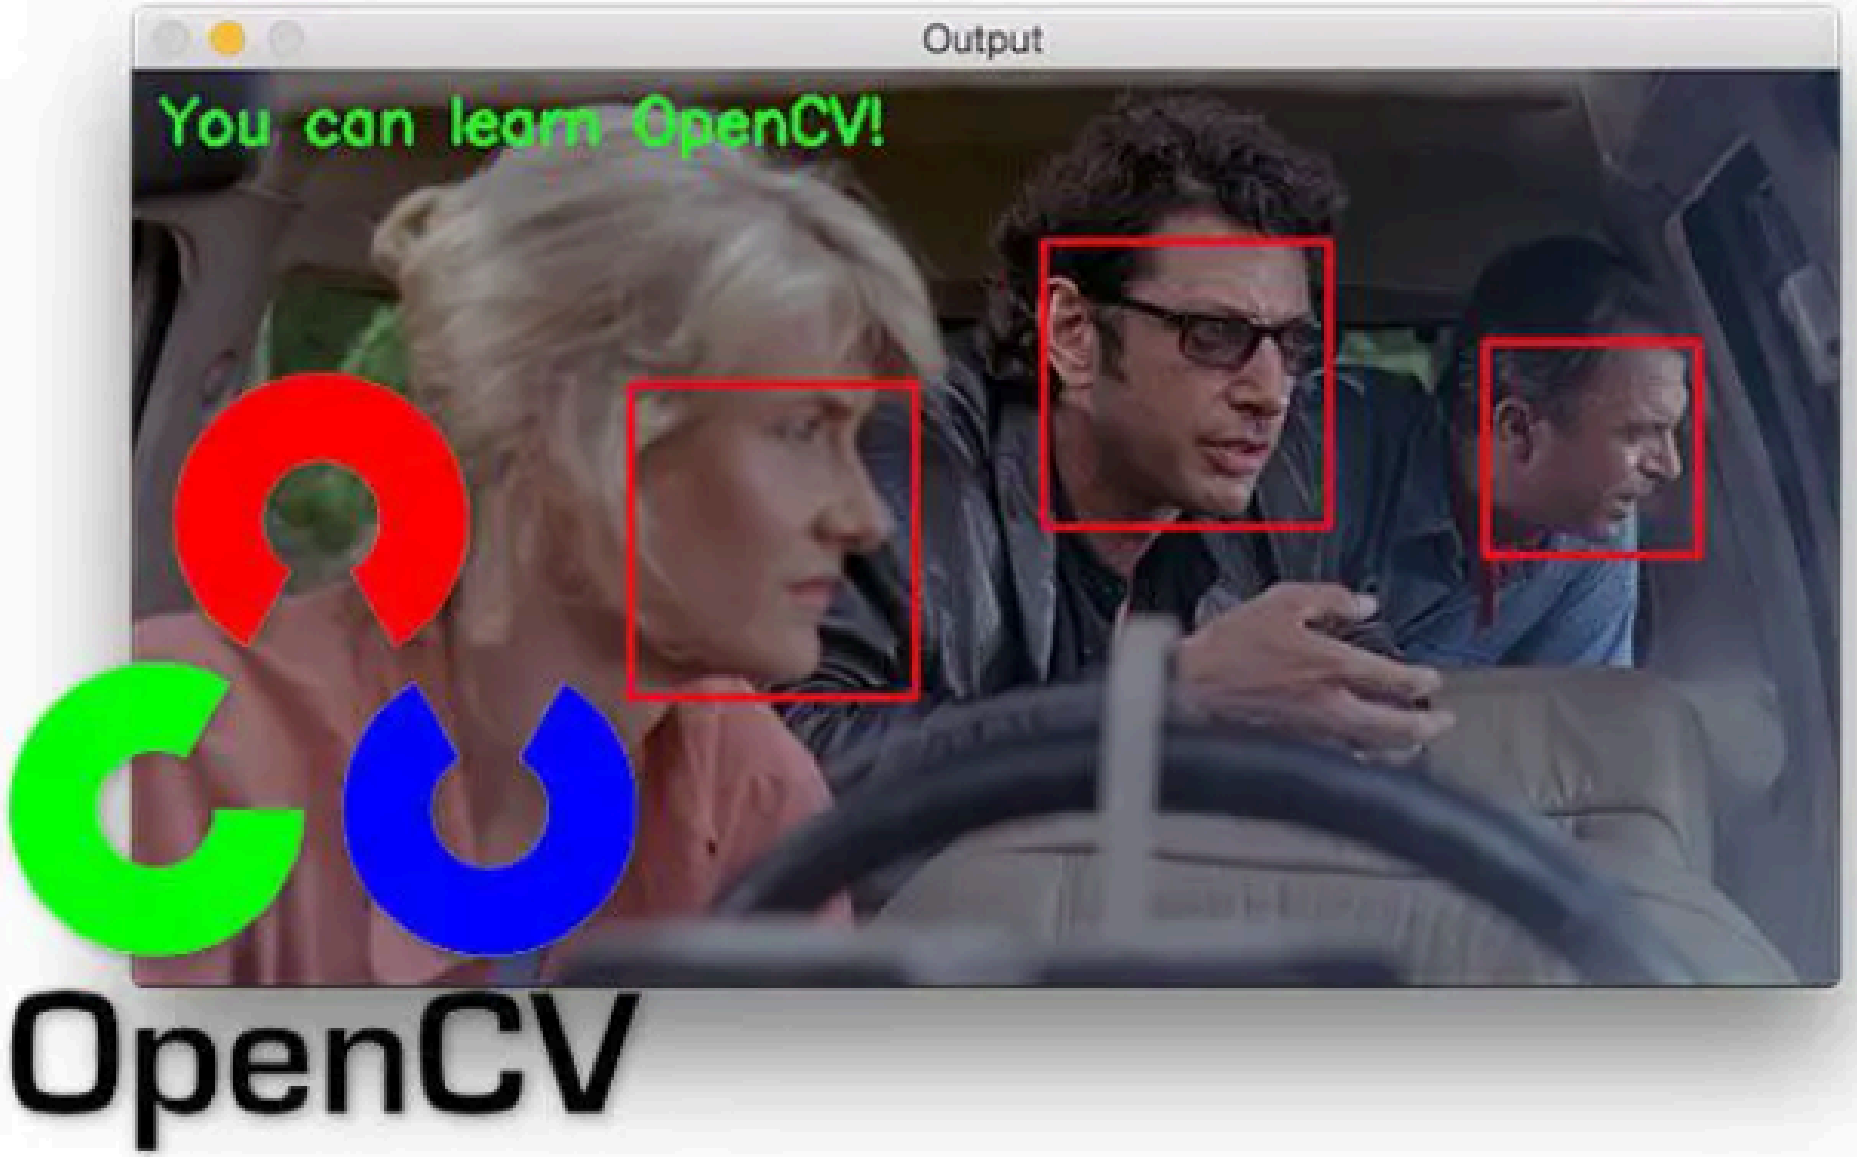
Video VLM 아키텍처 3가지 패턴

패턴	방식	대표
① Frame Sampling	프레임을 균등/장면 기반으로 뽑아 이미지 여러 장으로 전달	로컬 VLM(Qwen3-VL 등), 대부분의 오픈소스
② Native Video Encoder	시공간(spatio-temporal) 토큰을 압축하는 전용 인코더 내장	Gemini, Qwen2.5-VL(video 모드)
③ 오디오 결합	프레임 이해 + STT(음성 인식) 트랜스크립트를 함께 활용	자막/강의 영상 등

> 이 강의는 로컬 환경(Ollama + Qwen3-VL) 기준이므로 ① **Frame Sampling 방식**을 실습 기준으로 함

2. 영상 입력 처리 (OpenCV 연계)

- 영상 메타데이터 읽기
- Frame 추출 전략
- 전처리와 프레임 수 결정
- VLM에 프레임 전달하기


Output
You can learn OpenCV!
OpenCV

영상 메타데이터 읽기

- OpenCV `VideoCapture`로 fps, 총 프레임 수, 해상도, 재생 시간 확인
- 샘플링 전략을 정하기 전에 반드시 먼저 확인해야 하는 값들

```
import cv2

cap = cv2.VideoCapture("video.mp4")
fps = cap.get(cv2.CAP_PROP_FPS)
frame_count = cap.get(cv2.CAP_PROP_FRAME_COUNT)
duration_sec = frame_count / fps
width, height = cap.get(cv2.CAP_PROP_FRAME_WIDTH), cap.get(cv2.CAP_PROP_FRAME_HEIGHT)
```

Frame 추출 전략 비교

전략	방식	장점	단점
균등 샘플링 (Uniform)	N등분해서 일정 간격으로 추출	구현 간단, 전체 흐름 파악에 유리	짧은 이벤트를 놓칠 수 있음
장면전환 감지 (Scene-change)	프레임 간 픽셀/히스토그램 차이가 클 때만 추출	컷이 바뀌는 지점을 놓치지 않음	정적인 장면에서는 프레임이 거의 안 뽑힘
고정 fps 샘플링	예: 1초에 1장씩 추출	시간 간격이 균일해 타임스탬프 매핑이 쉬움	영상 길이에 비례해 프레임 수 증가

> 실무에서는 **고정 fps 샘플링**을 기본값으로 하고, 이벤트 탐지처럼 정밀도가 필요하면 장면전환 감지를 보조로 사용

전처리와 프레임 수 결정

- Resize: VLM 입력 해상도에 맞춰 축소(속도·비용 절감, 과도한 축소는 텍스트/디테일 손실)
- **프레임 수** = **토큰 비용** → 몇 장을 넣을지가 정확도와 속도의 트레이드오프

프레임 수	특징
4~8장	빠르고 저렴, 짧은 영상 요약에 적합, 세부 이벤트 놓치기 쉬움
16~32장	정확도와 비용의 균형, 대부분의 실습에 권장
32장 이상	정밀하지만 느리고 비용 증가, 긴 영상엔 비효율적

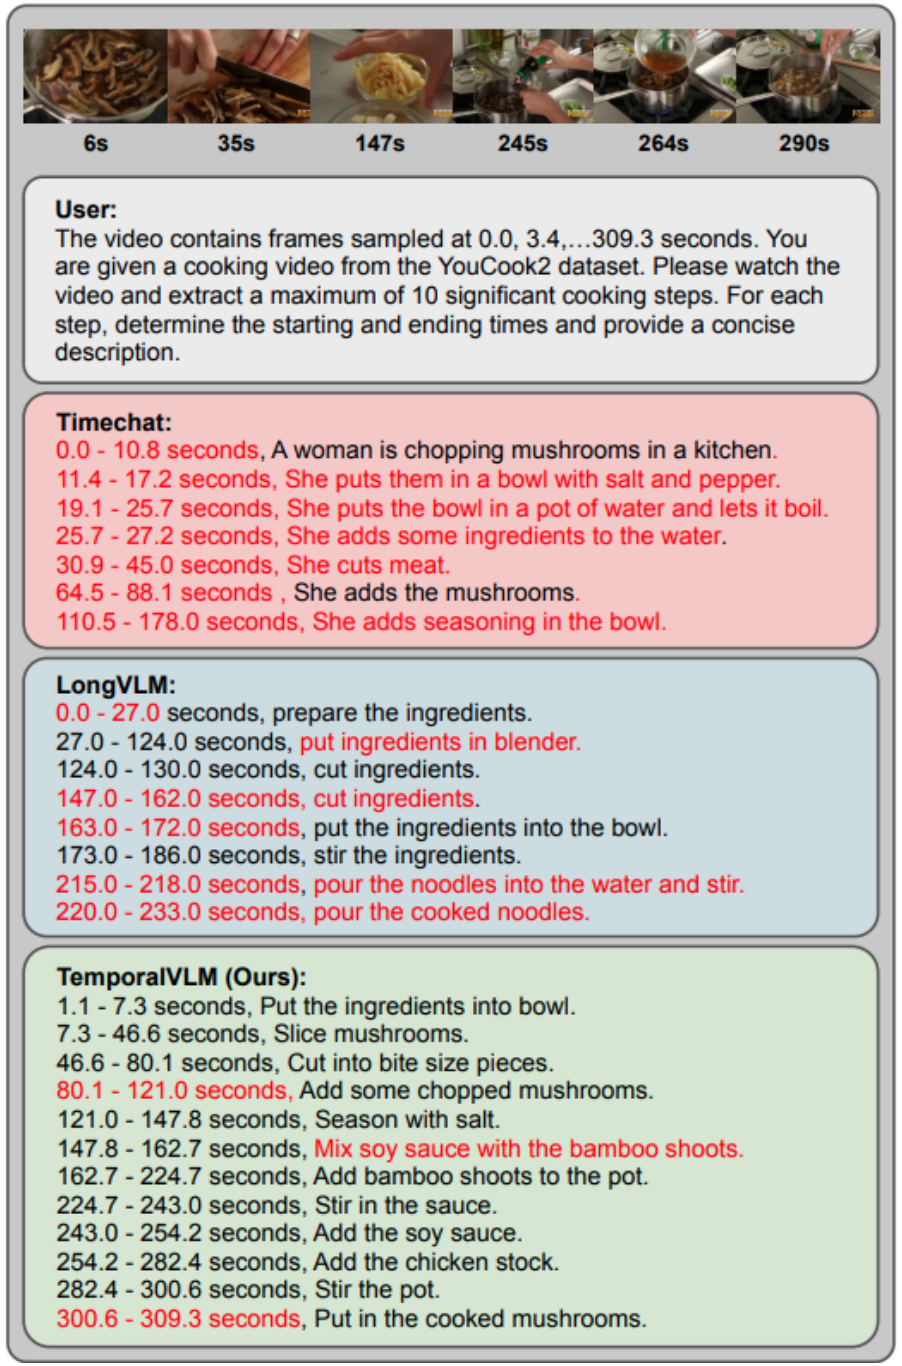
VLM에 프레임 전달하기

- Ollama `chat`의 `images`는 리스트 → **한 메시지에 여러 프레임을 순서대로 담아 전달**
- 프롬프트에 "프레임 순서" 또는 "N초 지점"을 명시해야 모델이 시간 순서를 인지

```
response = ollama.chat(
    model="qwen3-vl:4b",
    messages=[{
        "role": "user",
        "content": "아래는 영상에서 0.5초 간격으로 추출한 프레임 1~8번이야. 시간 순서대로 무슨 일이 일어나는지 설명해줘.",
        "images": [f1, f2, f3, f4, f5, f6, f7, f8],
    }],
)
```

3. Temporal Reasoning (시간적 추론)

- 순서 · 변화 · 인과 추론
- 타임스탬프 Grounding
- 실패 사례와 한계
- 구조화된 타임라인 출력



순서 · 변화 · 인과 추론

- 단일 프레임 질의: "이 이미지에 뭐가 있어?"
- Temporal Reasoning: "**무엇이 먼저고 무엇이 나중인지**", "**무엇이 바뀌었는지**", "**왜 이런 일이 일어났는지**"
- 대표 태스크: 순서 판단, 변화(diff) 감지, 이벤트 경계(boundary) 탐지

```
[나쁜 예] 이 영상에 뭐가 나와?
[좋은 예] 프레임 1번부터 8번까지 순서대로 봤을 때,
          등장인물의 행동이 어떻게 바뀌는지 시간 순서대로 설명해줘.
```

타임스탬프 Grounding

- 프레임에 "몇 번째" 대신 "**몇 초 지점**"을 명시하면 답변에 시간 정보가 딸려 나옴 → 이후 이벤트 탐지에 필수
- 프롬프트에 각 프레임의 타임스탬프를 명시적으로 나열해 전달

```
아래 프레임은 각각 0초, 2초, 4초, 6초, 8초 지점이야.
공이 골대에 들어가는 순간이 몇 초 지점인지 알려줘.
```

실패 사례와 한계

- **샘플링 간격보다 빠른 이벤트**: 프레임 사이에서 일어난 일은 아예 못 봄 (예: 8초 안에 스쳐 지나간 사건)
- **환각(Hallucination)**: 실제로 없는 사건을 "봤다"고 답하는 경우 — 특히 프레임 수가 적을 때 심함
- **오디오 정보 부재**: 대사·음악·효과음은 프레임에 없음 → 오디오 의존 콘텐츠는 파악 불가

> 대응: "제공된 프레임에서 확인되지 않으면 추측하지 말고 '확인 불가'라고 답해"를 프롬프트에 명시

구조화된 타임라인 출력

- 이벤트 탐지 결과를 후속 처리 가능한 형태로 고정

```
{
  "events": [
    {"timestamp_sec": 4, "event": "goal", "description": "공이 골대 오른쪽으로 들어감"},
    {"timestamp_sec": 12, "event": "celebration", "description": "선수들이 환호"}
  ]
}
```

4. Video AI 실습 태스크

- 영상 요약
- 이벤트 탐지
- 행동 분석

영상 요약 (Video Summarization)

- 균등 샘플링한 프레임 전체를 한 번에 전달 → 전체 줄거리/핵심 장면 요약
- 프롬프트 설계: 요약 길이, 시청자 대상(예: "3줄 요약"), 핵심 장면 선정 기준 명시

```
아래 프레임들은 영상 전체를 균등한 간격으로 추출한 것이야.
이 영상에서 일어나는 일을 시간 순서대로 3~4문장으로 요약해줘.
```

이벤트 탐지 (Event Detection)

- "특정 사건이 몇 초에 일어났는가"를 찾는 태스크 → 3강에서 배운 구조화된 출력과 결합
- 스포츠 하이라이트, CCTV 특이사항, 강의 챕터링 등에 응용

```
아래 프레임들에서 "문이 열리는 순간"이 몇 초 지점인지 찾아서
{"timestamp_sec": number, "description": string} 형식의 JSON으로만 답해.
```

행동 분석 (Action Recognition)

- 사람/사물의 동작을 분류하거나, 평소와 다른 행동(이상행동)을 탐지
- CCTV 이상행동 탐지처럼 "정상 범주"를 프롬프트에 정의해주면 정확도 상승

```
아래는 CCTV 영상에서 추출한 프레임이야.
정상적인 보행 외에 넘어짐, 배회, 물건 방치 같은 이상행동이
보이면 몇 번째 프레임에서 어떤 행동인지 설명해줘. 없으면 "이상없음"이라고 답해.
```

5. 긴 영상 다루기 — Video RAG

- 문제: 토큰 한계
- 클립 분할과 요약 임베딩
- Video RAG 파이프라인
- ViTA: 효율적인 Video-to-Text 변환
- 이미지 RAG와의 차이

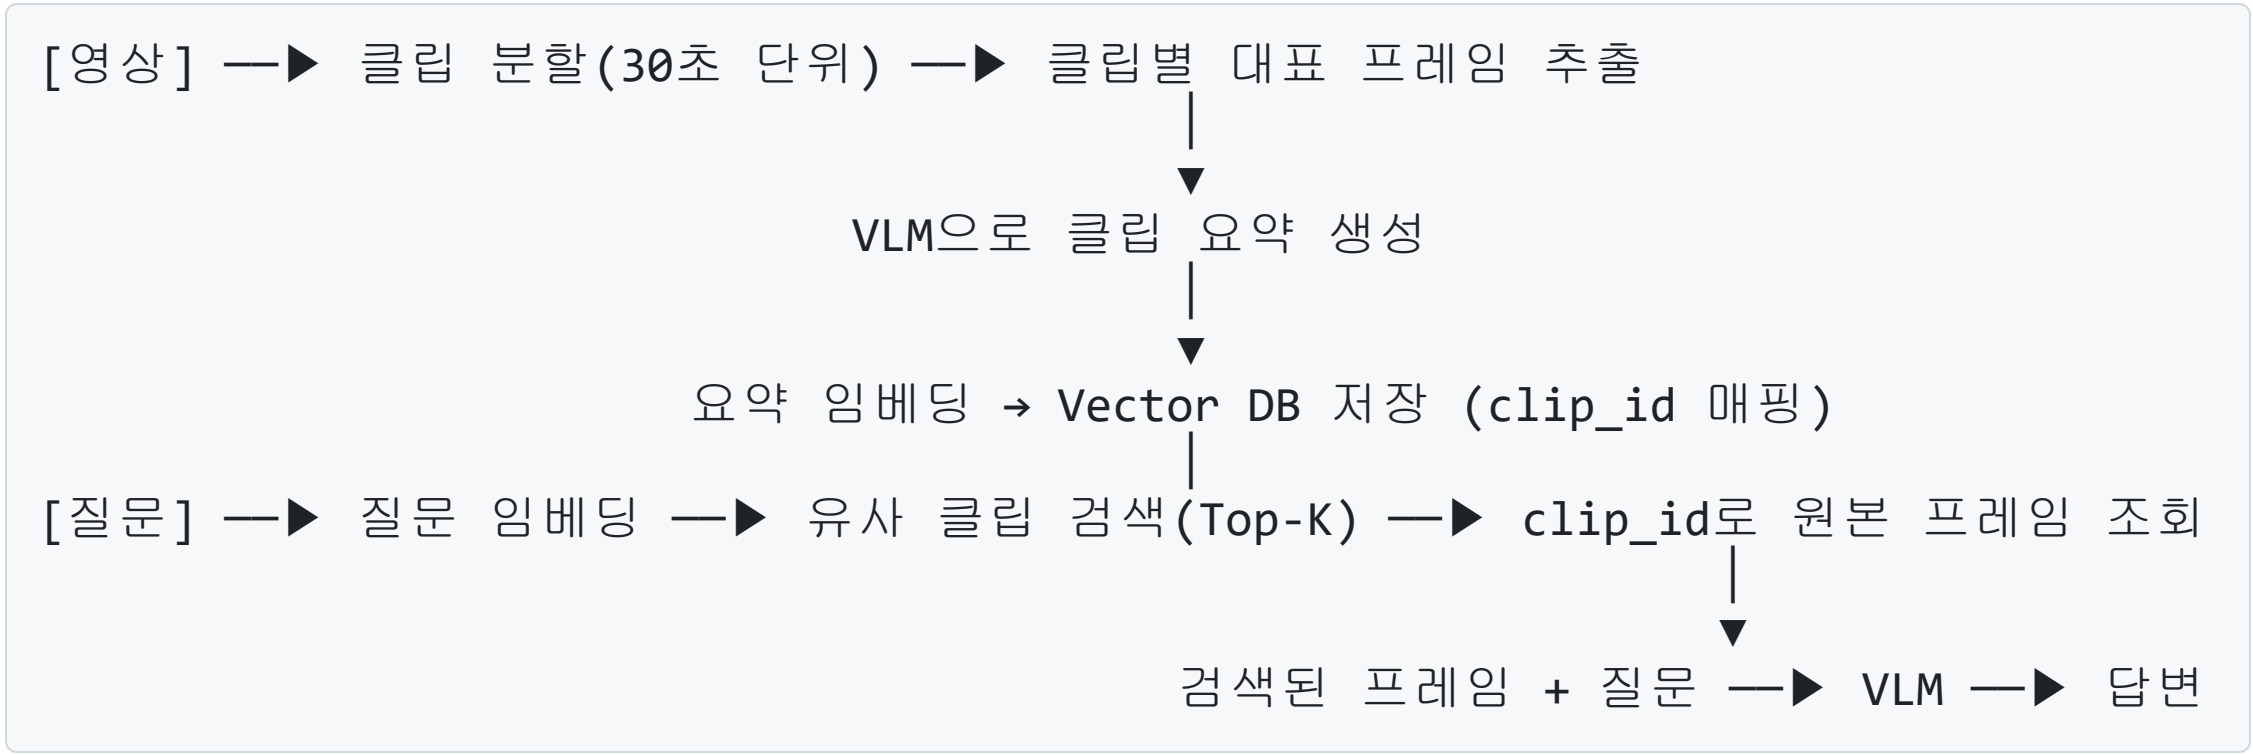
문제: 토큰 한계

- 10분 이상 영상은 프레임을 아무리 듬성듬성 뽑아도 한 번에 다 넣기 어려움
- 『Multimodal RAG』에서 "PDF를 페이지 단위로 쪼개 검색"했던 것처럼, 영상도 **구간(클립) 단위로 쪼개서 검색**해야 함
- 긴 영상 분석에서는 "VLM이 영상을 이해할 수 있는가"뿐 아니라 **얼마나 빠르고 저렴하게 텍스트로 변환할 수 있는가**가 중요해짐

클립 분할과 요약 임베딩

- 영상을 고정 길이(예: 30초) 또는 장면전환 기준 **클립 단위**로 분할
- 각 클립에서 대표 프레임을 뽑아 VLM으로 **텍스트 요약** 생성 → 요약을 임베딩해 Vector DB에 저장
- 『Multimodal RAG』 강의 3장의 **Multi-Vector Retriever 패턴** 그대로 재사용
  - Vector Store: 클립 요약의 임베딩 (검색 전용)
  - Document Store: 클립의 원본 프레임들 (답변 생성 전용)

Video RAG 파이프라인



Video-to-Text 변환의 병목

Video RAG에서 가장 시간이 오래 걸리는 단계는 보통 **클립별 텍스트 요약 생성**

- 클립 수가 많을수록 VLM 호출 횟수 증가
- 큰 VLM은 장면을 자세히 설명하지만 느림
- 출력 토큰이 길수록 응답 시간이 길어짐
- 요약이 너무 짧으면 검색에 필요한 정보가 빠짐
- 요약이 너무 길면 중복이 많고 저장/검색 비용도 증가

> Video RAG의 품질은 "좋은 검색" 이전에 **좋은 video-to-text 변환**에 크게 좌우됨

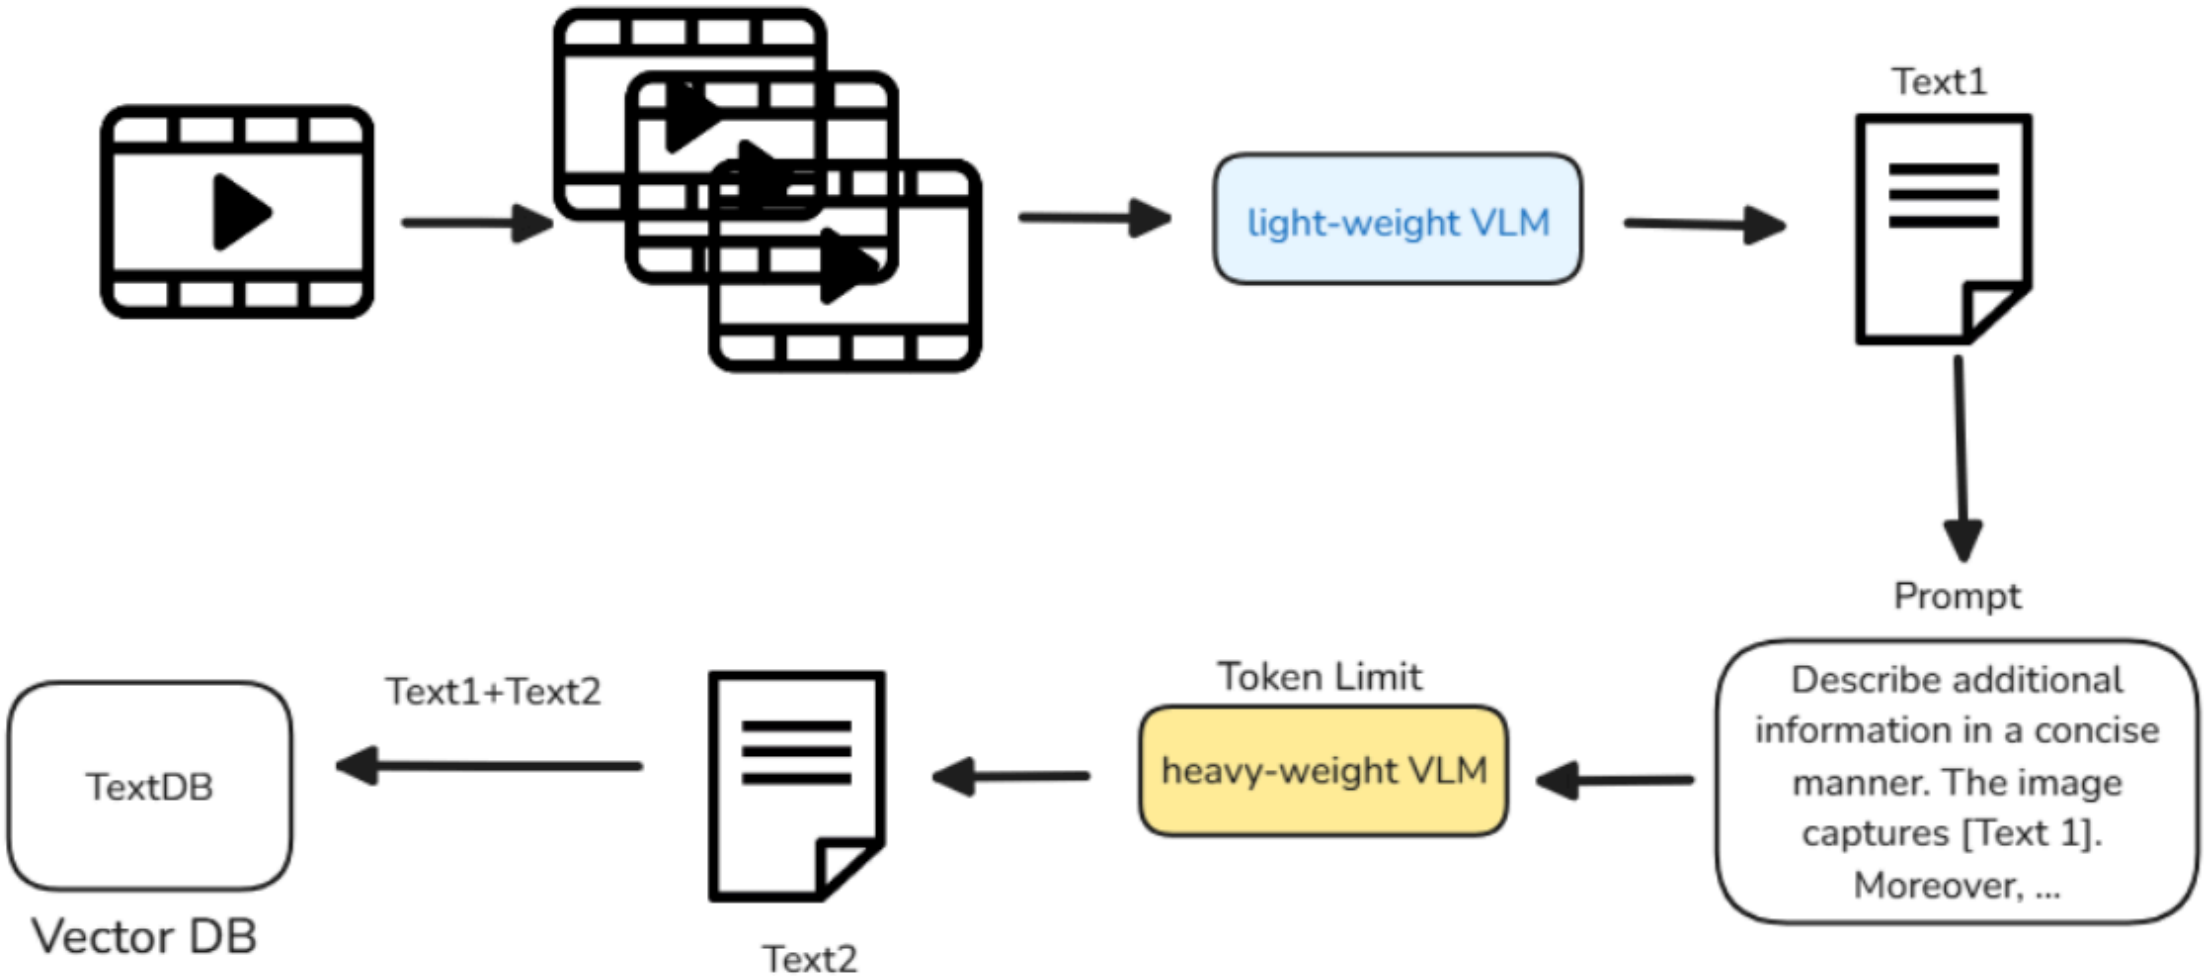
ViTA: 효율적인 Video-to-Text

ViTA는 긴 영상을 RAG에 넣기 위해 **영상 클립을 빠르게 텍스트로 변환**하는 접근

핵심 아이디어

1. Lightweight VLM으로 클립의 대략적인 내용을 빠르게 요약
2. Heavyweight VLM은 빠른 요약을 참고해 부족한 세부 정보만 짧게 보강
3. 두 결과를 합쳐 Vector DB에 저장

> ViTA는 모델을 fine-tuning하는 방법이 아니라, **Video RAG 파이프라인을 빠르게 만드는 시스템 최적화 전략**

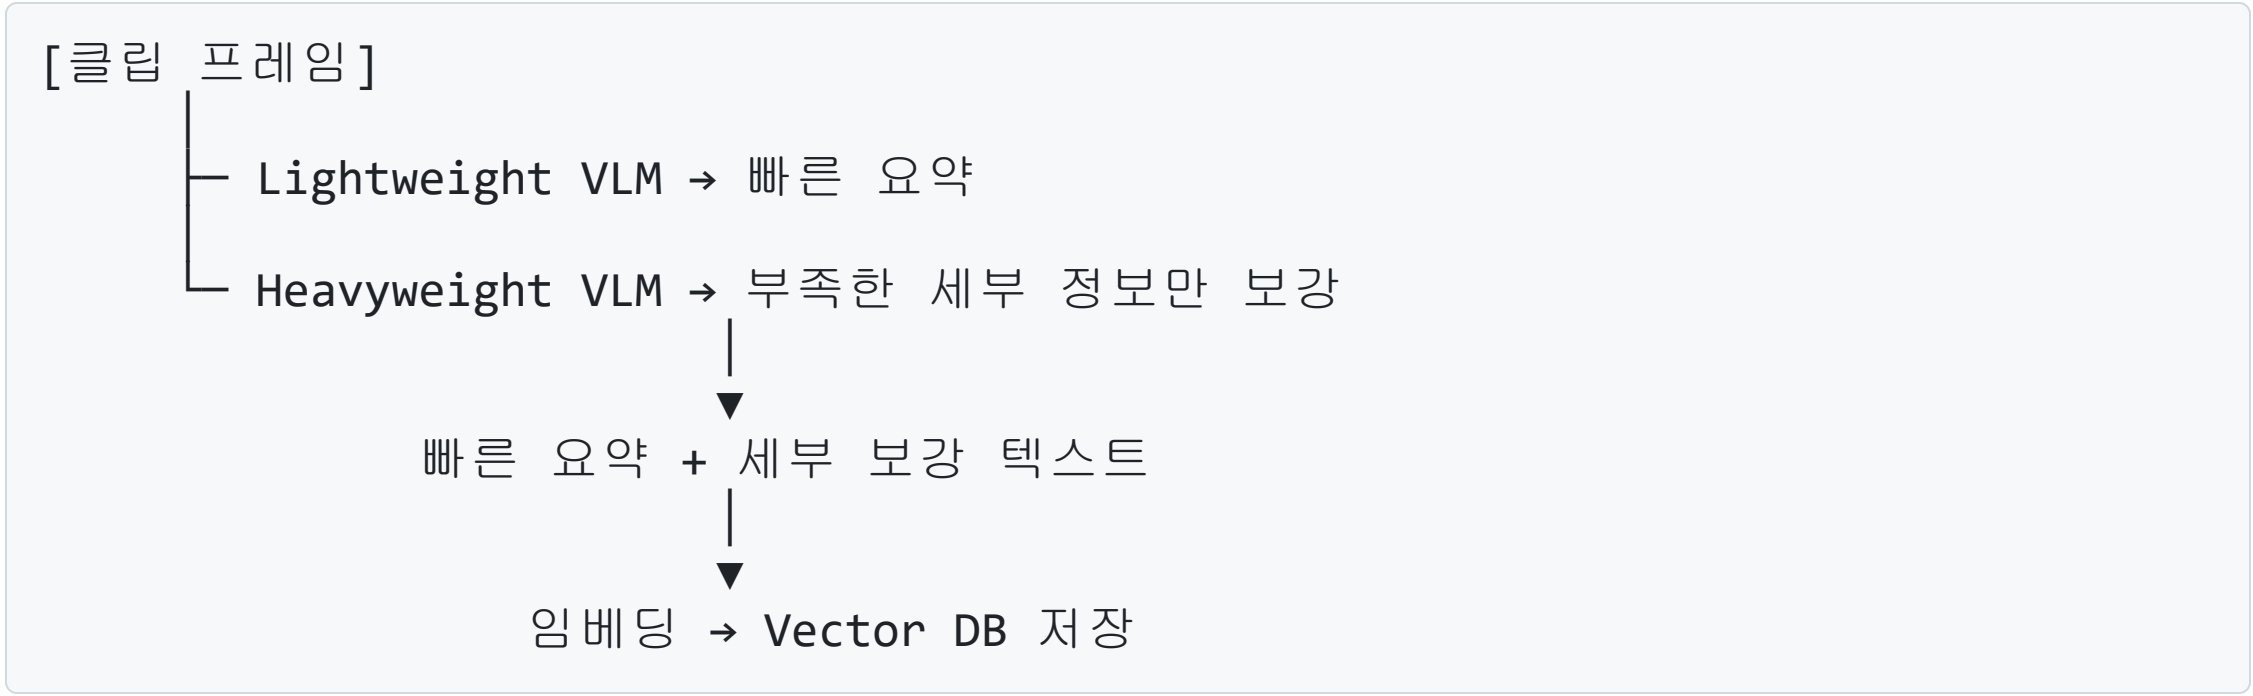

light-weight VLM
Text1
Prompt
Describe additional information in a concise manner. The image captures [Text 1]. Moreover, ...
Token Limit
heavy-weight VLM
Text2
Text1+Text2
TextDB
Vector DB

Lightweight VLM vs Heavyweight VLM

구분	Lightweight VLM	Heavyweight VLM
역할	빠른 장면 파악	세부 정보 보강
장점	속도 빠름, 비용 낮음	설명 풍부, 추론력 높음
단점	세부 정보 누락 가능	느림, 비용 높음
사용 방식	클립 전체의 gist 생성	빠진 정보만 제한 토큰으로 생성

> 모든 클립을 큰 모델로 길게 설명하는 대신, **작은 모델로 초안을 만들고 큰 모델로 필요한 부분만 보강**

ViTA 파이프라인



실습에서는 같은 로컬 VLM을 사용하되,
프레임 수·해상도·출력 토큰 수를 다르게 설정해 두 역할을 흉내낼 수 있음

ViTA를 적용할 때의 주의점

- 빠른 요약이 틀리면 세부 보강도 영향을 받을 수 있음
- 두 모델의 출력이 중복되면 저장 텍스트가 길어지고 검색 효율이 떨어짐
- 토큰 제한을 너무 강하게 걸면 중요한 객체/행동이 빠질 수 있음
- 도메인마다 "검색에 필요한 정보"가 다르므로 프롬프트 조정이 필요

> 핵심은 짧게 쓰는 것이 아니라, **검색에 필요한 정보를 밀도 있게 남기는 것**

이미지 RAG와의 차이

- 검색 결과가 여러 개일 때, **시간 순서를 보존**해서 프롬프트에 전달해야 함 (이미지 RAG는 순서 무관)
- 인접 클립 간 맥락이 이어지는 경우가 많아 **Top-K 클립 + 전후 클립**을 함께 전달하면 답변 품질 상승

> "K번째 클립"이 아니라 "N분 M초 구간"으로 답변하도록 프롬프트에 명시 — 사용자가 실제 영상에서 바로 확인 가능

6. 실전 활용과 한계

- 대표 Use Case
- ViTA의 위치
- 트레이드오프
- 한계

대표 Use Case

- **보안/CCTV**: 이상행동 탐지, 특정 시간대 이벤트 검색
- **스포츠**: 하이라이트 구간 자동 탐지
- **교육**: 강의 영상 챕터 자동 분할 및 요약
- **콘텐츠 모더레이션**: 부적절한 장면 탐지

ViTA의 위치

방법	해결하려는 문제	이 강의에서의 위치
Video RAG	긴 영상 검색·질의응답	긴 영상을 클립 단위로 저장/검색
ViTA	Video-to-Text 변환 비용	클립 요약 생성 단계 최적화

> ViTA는 VLM을 fine-tuning하는 내용이 아니라, **영상 VLM을 실무 파이프라인에 맞게 쓰는 방법**

트레이드오프

요소	늘리면	줄이면
프레임 수	정확도 ↑, 비용/지연시간 ↑	속도 ↑, 짧은 이벤트 놓칠 위험 ↑
클립 길이(Video RAG)	검색 정확도 ↓ (클립이 뭉뚱그려짐)	클립 수 ↑ → 임베딩/저장 비용 ↑
출력 토큰 수(ViTA)	설명 풍부, 지연시간 ↑	속도 ↑, 세부 정보 누락 위험 ↑

한계

- **오디오 정보 부재**: 프레임 기반 VLM은 소리를 못 봄 → 대사 중심 콘텐츠는 STT 결합 필요
- **빠른 모션**: 샘플링 간격보다 빠른 동작은 인식 불가
- **비용**: 긴 영상을 자주 분석해야 하는 경우 클립 캐싱/사전 인덱싱 전략 필수
- **설명 신뢰성**: VLM이 그럴듯한 근거를 만들어낼 수 있으므로, 프레임·시간 근거를 함께 확인해야 함